

Insights sobre Variáveis Textuais e Numéricas

Hackathon ONE · Alura + Oracle (OCI) — G9 Team 20

Documento de apoio à apresentação final, consolidando as descobertas sobre o comportamento das variáveis textuais (descrição de transação) e numéricas (renda, endividamento, gastos) usadas nos dois modelos do projeto.

1. Variáveis Textuais — Descrição da Transação

O que é essa variável

A coluna **descricao** (ex: "Uber", "Netflix", "Supermercado Extra") é a única entrada do modelo de classificação de categoria (Fase 5). Todo o aprendizado do modelo depende exclusivamente do texto — não há nenhuma outra informação estrutural (não sabemos, por exemplo, o CNPJ ou o segmento oficial do estabelecimento).

Insight 1 — Nomes de marca puros não geram sinal generalizável

Descoberta: um modelo treinado apenas com nomes próprios ("Extra", "Netflix", "Uber") atinge 100% de acurácia em teste com split ingênuo, mas cai para **15,7%** quando testado com estabelecimentos genuinamente nunca vistos. Nomes de marca são strings arbitrárias — não carregam nenhuma pista textual sobre a categoria a que pertencem.

Implicação prática: o mesmo problema existe no mundo real — é por isso que sistemas de pagamento reais usam o **MCC (Merchant Category Code)**, um código atribuído pela adquirente no momento da venda, em vez de depender só do nome fantasia.

Insight 2 — Palavras genéricas de categoria são o sinal que realmente generaliza

Descoberta: ao reformular as descrições para incluir uma palavra genérica junto ao nome de marca (ex: "Supermercado Extra" em vez de só "Extra"; "Farmácia Pague Menos" em vez de só "Pague Menos"), a acurácia em estabelecimentos nunca vistos subiu de 15,7% para **46,3%**, e depois para **87,7%** após reforço adicional de vocabulário.

Implicação prática: em qualquer sistema real de classificação de texto curto, o vocabulário de treino precisa cobrir os **termos genéricos e funcionais** que o usuário realmente digita (ex: "Combustível", "Conta de Luz", "Remédio"), não apenas nomes de marca.

Insight 3 — Ambiguidade de palavra-chave entre categorias prejudica a precisão

Descoberta: palavras que aparecem em mais de uma categoria (ex: "Restaurante" em Alimentação e em Lazer; "Seguro" em Moradia e em Transporte) confundem o modelo, gerando previsões enviesadas para uma categoria "padrão" quando o texto de teste é ambíguo.

Implicação prática: curadoria de vocabulário precisa checar sobreposição de palavras entre classes, não só riqueza de vocabulário dentro de cada classe isoladamente.

Insight 4 — Redundância de palavra-chave é mais importante que volume total de vocabulário

Descoberta: aumentar o número total de estabelecimentos (de 98 para 148) não resolveu, sozinho, a instabilidade de resultado entre execuções. O fator decisivo foi garantir que **cada palavra-chave genérica aparecesse em pelo menos 3-4 estabelecimentos diferentes** por categoria — reduzindo a chance de uma palavra-chave "sumir" do treino por azar do sorteio de teste.

Insight 5 — N-gramas de 2 palavras (bigramas) ajudam a desambiguar

Descoberta: o vetorizador TF-IDF foi configurado com `ngram_range=(1, 2)` — considerando não só palavras isoladas, mas pares de palavras. Isso ajudou a diferenciar, por exemplo, "Seguro Residencial" (Moradia) de "Proteção Veicular Porto Seguro" (Transporte), mesmo com a palavra "Seguro" presente nos dois casos.

Insight 6 — Avaliação de texto com vocabulário pequeno exige múltiplos testes, não um só

Descoberta: com um vocabulário de 150-230 palavras únicas, um único sorteio de split treino/teste produziu resultados de acurácia variando entre **76% e 93%** em execuções sucessivas, sem nenhuma mudança real no modelo ou nos dados. A causa: a "dificuldade" de cada sorteio de teste varia conforme quais estabelecimentos específicos calham de ficar de fora do treino.

Solução metodológica: validação cruzada com 10 rodadas (sementes diferentes), reportando média e desvio padrão — **86,79% ± 5,33%** foi a métrica final considerada confiável, substituindo qualquer leitura isolada.

Resumo estatístico do vocabulário textual final

Métrica	Valor
Total de transações no dataset	10.000
Estabelecimentos únicos	161
Palavras únicas no vocabulário (após tokenização)	233
Categorias	7
Acurácia média (validação cruzada, 10 rodadas)	86,79% ($\pm$ 5,33%)
F1-macro médio	86,26% ($\pm$ 6,56%)

2. Variáveis Numéricas — Perfil Financeiro e Transações

O que são essas variáveis

Usadas em dois contextos diferentes:

- **No dataset de transações (Fase 4):** **valor** da transação, gerado a partir de médias reais do IBGE
- **No dataset de perfil (Fase 6):** **renda_mensal**, **nivel_endividamento**, **frequencia_poupanca**, **comprometimento_gastos**, e o valor gasto em cada uma das 7 categorias

Insight 1 — Gasto mensal agregado $\neq$ valor de uma transação individual

Descoberta: as médias do IBGE (ex: R\$ 658,23/mês em Alimentação) representam a soma de várias compras no mês, não uma compra isolada. Ao gerar transações sintéticas, dividir a média mensal por uma frequência simulada de compras (8 a 20 vezes/mês, dependendo da categoria) produziu valores de transação individual muito mais realistas — caindo de uma média de R\$ 658 para uma média de **R\$ 54-56** por transação de Alimentação, por exemplo.

Categoria	Valor médio por transação (R\$)	Faixa observada (R\$)
Moradia	354,79	57 – 1.772
Saúde	169,01	27 – 1.452
Educação	113,69	18 – 564
Transporte	45,28	8 – 196
Alimentação	54,57	10 – 230
Serviços	27,66	3 – 160
Lazer	25,72	4 – 197

Insight 2 — Distribuição log-normal reproduz melhor o comportamento real de gasto

Descoberta: valores financeiros reais (renda, gasto por transação) tendem a ter uma distribuição assimétrica — muitos valores baixos, poucos valores muito altos, nunca valores negativos. Usar `np.random.lognormal` (em vez de distribuição normal comum ou uniforme) para gerar tanto os valores de transação quanto a renda mensal sintética reproduziu esse padrão de forma mais fiel à realidade econômica.

Insight 3 — Endividamento segue padrão de cauda longa, não distribuição uniforme

Descoberta: ao gerar os 5.000 perfis financeiros sintéticos, o `nivel_endividamento` foi sorteado de uma distribuição **Beta(a=2, b=5)**, deliberadamente enviesada para valores baixos — refletindo que a maioria da população não está fortemente endividada, mas com uma cauda que ainda permite casos de endividamento alto. O resultado da rotulagem confirma essa expectativa:

Perfil financeiro	Quantidade	Percentual
Saudável	2.205	44,1%
Em observação	2.137	42,7%
Em risco	658	13,2%

Insight 4 — `nivel_endividamento` é, disparadamente, a variável mais decisiva do modelo de perfil

Descoberta: a importância de variável extraída do Random Forest (Fase 6) mostra uma concentração extrema de poder preditivo em apenas duas variáveis:

Variável	Importância
<code>nivel_endividamento</code>	69,8%
<code>comprometimento_gastos</code>	15,6%
<code>renda_mensal</code>	2,9%
<code>frequencia_poupanca</code> (codificada)	1,9%
Cada categoria de gasto individual (Moradia, Transporte, etc.)	1,2% – 1,8% cada

Implicação prática: isso confirma que o modelo não está "decorando" nada — ele reconstruiu corretamente a lógica da regra de negócio que gerou os próprios rótulos, já que essas são exatamente as duas variáveis usadas nos limiares de decisão (30%/50%).

Insight 5 — Codificação ordinal supera one-hot para variáveis com ordem natural

Descoberta: `frequencia_poupanca` ("Baixa", "Média", "Alta") foi codificada como valores ordinais (0, 1, 2), não como one-hot encoding. Isso preserva a relação de ordem entre as categorias, o que ajuda modelos baseados em árvore (como o Random Forest) a aprender limiares de decisão de forma mais direta do que trataria variáveis categóricas sem relação de ordem.

Insight 6 — Variável derivada (`comprometimento_gastos`) tem mais poder preditivo que variáveis brutas de gasto por categoria

Descoberta: a variável calculada `comprometimento_gastos` (soma dos gastos ÷ renda mensal, em percentual) teve importância de 15,6% — muito maior que qualquer categoria de gasto isolada (todas abaixo de 2%). Isso é um exemplo concreto de **engenharia de atributos** bem sucedida: uma variável derivada capturou um padrão relevante (proporção do orçamento comprometida) que as variáveis brutas, sozinhas, não expunham tão claramente ao modelo.

Insight 7 — Alta acurácia é confiável quando o rótulo é determinístico, suspeita quando não é

Contraste entre as duas fases de modelagem: no modelo de perfil (variáveis numéricas, rótulo gerado por regra determinística), uma acurácia de 99,6% é esperada e correta. No modelo de categoria (variável textual, rótulo por vocabulário), o mesmo patamar de acurácia era sinal de overfitting. A distinção depende de **como o rótulo foi gerado**, não do valor da métrica isoladamente — um ponto metodológico importante para qualquer avaliação de modelo.

3. Quadro-Resumo para a Apresentação

Tipo de variável	Desafio principal encontrado	Solução aplicada
Textual (descrição)	Vocabulário fechado gera falsa generalização	Palavras genéricas + redundância + validação cruzada
Textual (descrição)	Ambiguidade entre categorias	Curadoria manual de sobreposição + bigramas
Numérica (valor de transação)	Média agregada $\neq$ valor individual	Divisão por frequência simulada + distribuição log-normal
Numérica (perfil financeiro)	Ausência de rótulo pronto	Regra de negócio fundamentada em dado real (BCB)
Numérica (perfil financeiro)	Variáveis brutas com baixo poder preditivo isolado	Engenharia de atributo derivado (<code>comprometimento_gastos</code>)